

**МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ "ЛЬВІВСЬКА ПОЛІТЕХНІКА"**

**Інститут ІКНІ
Кафедра СШІ**



ЗВІТ

до лабораторної роботи № 1

з дисципліни: “Інтелектуальний аналіз та візуалізація даних”
на тему: “Вхідний аналіз набору даних”

Лектор:
Виклюк Я.І

Виконав:
ст. гр. ШІ-31
Корнілов А. С.

Прийняла:
Торська Р.В.
« 18 » вересня 2026 р.

Тема роботи: вхідний аналіз набору даних

Мета роботи: пригадати роботу в Jupyter Notebook, бібліотеці `pandas` та побудову графіків і зробити це не на навчальному прикладі, а на реальному файлі, який ніхто не готував спеціально для вас.

РЕЗУЛЬТАТИ

Параметри варіанта № 10:

Цільовий потік частинок: $E > 2.0$ (потік електронів з енергією понад 2.0 MeV).

Пара для кореляційного графіка: радіопотік F10.7 та швидкість вітру.

Агрегат для аналізу добового ходу: мінімум.

Індивідуальне аналітичне питання: «Порівняйте медіану вашого потоку за перший і за другий тиждень спостережень. У скільки разів вони відрізняються?»

Етап 1. Первинний аналіз структури файлу

Стандартне зчитування викликом `pd.read_excel()` призвело до зміщення структури: службовий URL-рядок у заголовку файлу став назвами колонок, порожні поля набули імен `Unnamed:`, а числові значення інтерпретувалися як текстовий тип `object`.

	Unnamed: 0	ftp://ftp.swpc.noaa.gov/pub/lists/particle/	Unnamed: 2	Unnamed: 3	Unnamed: 4	Unnamed: 5	Unnamed: 6
0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
1	NaN	:Data_list: 20170901_Gs_part_5m.txt	NaN	NaN	NaN	NaN	NaN
2	NaN	:Created: 2017 Sep 02 0011 UTC	NaN	NaN	NaN	NaN	NaN
3	NaN	# Prepared by the U.S. Dept. of Commerce, NOAA...	NaN	NaN	NaN	NaN	NaN
4	NaN	# Please send comments and suggestions to SWPC...	NaN	NaN	NaN	NaN	NaN
...	...	...	...	...	...	...	...
7220	NaN	2017	9	21	2335	58017	84900
7221	NaN	2017	9	21	2340	58017	85200
7222	NaN	2017	9	21	2345	58017	85500
7223	NaN	2017	9	21	2350	58017	85800
7224	NaN	2017	9	21	2355	58017	86100

Зчитування без заголовків (`header=None`) виявило реальний розмір матриці (7226 рядків, 32 стовпці).

0	1	2	3	4	5	6	7	8			
0	NaN	ftp://ftp.swpc.noaa.gov/pub/lists/particle/	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
1	NaN		NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
2	NaN	:Data_list: 20170901_Gs_part_5m.txt	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
3	NaN	:Created: 2017 Sep 02 0011 UTC	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
4	NaN	# Prepared by the U.S. Dept. of Commerce, NOAA...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
5	NaN	# Please send comments and suggestions to SWPC...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
6	NaN	#	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
7	NaN	# Label: P > 1 = Particles at >1 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
8	NaN	# Label: P > 5 = Particles at >5 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
9	NaN	# Label: P >10 = Particles at >10 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
10	NaN	# Label: P >30 = Particles at >30 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
11	NaN	# Label: P >50 = Particles at >50 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
12	NaN	# Label: P>100 = Particles at >100 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
13	NaN	# Label: E<0.8 = Electrons at <0.8 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N

Аналіз заповненості стовпців (RAW.notna().sum()) показав наявність трьох відокремлених блоків даних, розділених повністю порожніми стовпцями-роздільниками (індекси 0, 15, 20–23).

```

Col 9: 7198
Col 10: 7198
Col 11: 7198
Col 12: 7198
Col 13: 7198
Col 14: 7198
Col 15: 0
Col 16: 32
Col 17: 26
Col 18: 26
Col 19: 26
Col 20: 0
Col 21: 0
Col 22: 0
Col 23: 0
Col 24: 601
Col 25: 601
Col 26: 608
Col 27: 602
Col 28: 602
Col 29: 602
Col 30: 602
Col 31: 602

```

З текстових коментарів у шапці кожного блоку виписано фізичний зміст колонок та одиниці вимірювань.

```

=== ТАБЛИЦЯ 1 (стовпці 1-14) ===
ftp://ftp.swpc.noaa.gov/pub/lists/particle/
:Data_list: 20170901_6s_part_5m.txt
:Created: 2017 Sep 02 0011 UTC
# Prepared by the U.S. Dept. of Commerce, NOAA, Space Weather Prediction Center
# Please send comments and suggestions to SWPC.Webmaster@noaa.gov
#
# Label: P > 1 = Particles at >1 Mev
# Label: P > 5 = Particles at >5 Mev
# Label: P >10 = Particles at >10 Mev

```

Етап 2. Виділення таблиць та нормалізація часу

Сирий датасет розрізано на три незалежні DataFrame: A, B і C. Числові вимірювання приведено до типу з рухомою комою через `pd.to_numeric(..., errors='coerce')`.

```

32 B = B.dropna(how="all").apply(pd.to_numeric, errors="coerce").reset_index(drop=True)
33
34 cols_C = [
35     "Year",
36     "Month",
37     "Day",
38     "Hour",
39     "Proton_Speed",
40     "Proton_Density"
41 ]
42
43 C = RAW.iloc[27:, 26:32].copy()
44 C.columns = cols_C
45 C = C.dropna(how="all").apply(pd.to_numeric, errors="coerce").reset_index(drop=True)
46
47 print(f"Розмір таблиці A: {A.shape}")
48 print(f"Розмір таблиці B: {B.shape}")
49 print(f"Розмір таблиці C: {C.shape}")
✓ [8] 97ms

```

Розмір таблиці A: (7200, 14)
 Розмір таблиці B: (25, 4)
 Розмір таблиці C: (601, 6)

Зібрано уніфіковані часові мітки ts типу `datetime64[ns]`:
 для таблиці A: з колонок YR, MO, DA, HHMM (виділення годин діленням націло // 100 та хвилин залишком % 100);
 для таблиці B: за добовими мітками YR, MO, DA;
 для таблиці C: за колонками YR, MO, DA, HH з коригуванням двозначного формату року (YR + 2000 = 2017).

```

24
25 year_c = C["Year"].astype(int).apply(lambda y: y + 2000 if y < 100 else y)
26 C["ts"] = pd.to_datetime(
27     year_c.astype(str)
28     + "-"
29     + C["Month"].astype(int).astype(str).str.zfill(2)
30     + "-"
31     + C["Day"].astype(int).astype(str).str.zfill(2)
32     + " "
33     + C["Hour"].astype(int).astype(str).str.zfill(2)
34     + ":00:00"
35 )
36
37 print(f"Таблиця A: від {A['ts'].min()} до {A['ts'].max()}")
38 print(f"Таблиця B: від {B['ts'].min()} до {B['ts'].max()}")
39 print(f"Таблиця C: від {C['ts'].min()} до {C['ts'].max()}")
✓ [9] 136ms

Таблиця A: від 2017-08-28 00:00:00 до 2017-09-21 23:55:00
Таблиця B: від 2017-08-28 00:00:00 до 2017-09-21 00:00:00
Таблиця C: від 2017-08-28 00:00:00 до 2017-09-22 00:00:00

```

Валідація через блок `assert` підтвердила цілісність розмірів вибірок (A: 7200, B: 25, C: 601 рядок) та їхнє потрапляння у часове вікно 2017 року.

Самоперевірка етапу 2. Клітинка має виконатися без помилок.

```

1 assert len(A) == 7200, 'у таблиці A має бути 7200 рядків, а є %d' % len(A)
2 assert len(B) == 25, 'у таблиці B має бути 25 рядків, а є %d' % len(B)
3 assert len(C) == 601, 'у таблиці C має бути 601 рядок, а є %d' % len(C)
4 for назва, т in [('A', A), ('B', B), ('C', C)]:
5     рік = pd.to_datetime(т['ts']).dt.year
6     assert рік.min() == 2017 and рік.max() == 2017, 'у таблиці %s рік не 2017 – перевірте збирання дати' % назва
7 print('Етап 2 пройдено')
✓ [10] 85ms

Етап 2 пройдено

```

Етап 3. Паспорт даних та усунення артефактів

Описова статистика (`describe()`) виявила фізично некоректні від'ємні значення у таблиці C: мінімальні показники швидкості та густини сонячного вітру дорівнювали -1.0 (8 спостережень).

===== Таблиця А =====

- Розмір (рядків, стовпців): (7200, 15)
- Кількість повних дублікатів рядків: 0
- Типи даних та кількість пропусків (NaN):

	Dtype	Missing_Values
Year	int64	0
Month	int64	0
Day	int64	0
HHMM	int64	0

	Year	Month	Day	HHMM	Modified_Julian_Day	Seconds_of_Day	P_gt_1	P_gt_5
count	7200.0	7200.000000	7200.000000	7200.000000	7200.000000	7200.000000	7197.000000	7197.000000
mean	2017.0	8.840000	13.960000	1177.500000	58005.000000	43050.000000	689.325064	156.626057
min	2017.0	8.000000	1.000000	0.000000	57993.000000	0.000000	0.429000	0.151000
25%	2017.0	9.000000	7.000000	588.750000	57999.000000	21525.000000	11.700000	0.279000

Згідно зі службовим описом датчика SOHO CELIAS, значення -1.0 є апаратним кодом помилки передачі сигналу. Їх було замінено на np.nan. Після заміни статистика нормалізувалася: середня швидкість вітру зросла з 506.55 км/с до 513.39 км/с, мінімум зсунувся з -1.0 до фізично реальних 277.0 км/с; середня густина протонів зросла з 2.91 до 2.96 част/см³, мінімум став 0.1 част/см³.

```
# 2. Заміна від'ємних значень на NaN
C.loc[C["Proton_Speed"] < 0, "Proton_Speed"] = np.nan
C.loc[C["Proton_Density"] < 0, "Proton_Density"] = np.nan
```

```
=== Proton_Speed ===
```

```
Мінімум: до = -1, після = 277.0
```

```
Середнє: до = 506.5474, після = 513.3946
```

```
=== Proton_Density ===
```

```
Мінімум: до = -1.0, після = 0.1
```

```
Середнє: до = 2.9077, після = 2.9604
```

У таблиці А наявні стовпці (YR, MO, DA, HHMM, Julian_Day, Sec_of_Day), для яких обчислення середнього чи стандартного відхилення є беззмстовним, оскільки вони є порядковими календарними мітками, а не неперервними величинами вимірювань.

```
display(A.describe())
```

✓ [13] 154ms

	Year	Month	Day	HHMM	Modified_Julian_Day	Seconds_of_Day	P_gt_1	P_gt_5
count	7200.0	7200.000000	7200.000000	7200.000000	7200.000000	7200.000000	7197.000000	7197.000000
mean	2017.0	8.840000	13.960000	1177.500000	58005.000000	43050.000000	689.325064	156.626057
min	2017.0	8.000000	1.000000	0.000000	57993.000000	0.000000	0.429000	0.151000
25%	2017.0	9.000000	7.000000	588.750000	57999.000000	21525.000000	11.700000	0.279000
50%	2017.0	9.000000	13.000000	1177.500000	58005.000000	43050.000000	55.400000	0.632000
75%	2017.0	9.000000	19.000000	1766.250000	58011.000000	64575.000000	560.000000	107.000000
max	2017.0	9.000000	31.000000	2355.000000	58017.000000	86100.000000	32500.000000	2890.000000

Етап 4. Уніфікація дискретності, об'єднання та класифікація


Таблицю А (5-хвилинна сітка) згорнуто до погодинного кроку викликом `.resample('1h')` зі збереженням середнього (mean) та мінімального (min) значення для кожного потоку.

```
A_hourly = A.set_index("ts")[flux_cols].resample("1h").agg(["mean", "max", "min", "median"])

A_hourly.columns = [f"{col}_{stat}" for col, stat in A_hourly.columns]
A_hourly = A_hourly.reset_index()

print(f"Новий розмір таблиці A: {A_hourly.shape}")
A_hourly.head()
```

Порівняно погодинний хід середнього та максимуму потоку $E > 2.0$ за активну добу 07.09.2017: мінімум місцями значно значно менший за середнє під час різких сплесків, що підтверджує важливість збереження екстремумів при аналізі пікових навантажень на бортові системи космічних апаратів.



Об'єднання виконано методом `how='inner'`, що сформувало вибірку з 600 синхронних годин (метод `outer` давав 601 рядок через зайвий вимір датчика SOHO на початку доби 22 вересня).

Розмір M (inner): (600, 36)
 Розмір M (outer): (601, 36)

Кількість рядків з хоча б одним NaN у таблиці M: 8

	ts	P_gt_1_mean	P_gt_1_max	P_gt_1_min	P_gt_1_median	P_gt_5_mean	P_gt_5_max	P_gt_5_min	P_gt_5_me
175	2017-09-04 07:00:00	6.465833	10.10	4.37	6.275	0.262083	0.593	0.159	0.0
176	2017-09-04 08:00:00	4.010833	5.08	2.66	4.080	0.256000	0.432	0.168	0.0
177	2017-09-04 09:00:00	3.268333	4.42	2.26	3.040	0.303417	0.518	0.197	0.0
178	2017-09-04 10:00:00	3.179167	4.74	2.38	2.975	0.252167	0.372	0.171	0.0
179	2017-09-04 11:00:00	5.274167	7.98	3.69	4.535	0.295083	0.657	0.160	0.0

Виявлено серію пропусків (NaN) у показниках вітру тривалістю 8 годин поспіль (04.09.2017 з 07:00 до 14:00), спричинену початковою ударною хвилею сонячного спалаху. Додано класифікаційний стовпець група за пороговими рівнями потоку $P > 10_{\text{max}}$ відповідно до класифікатора космічної погоди NOAA: тиха (< 10): 411 годин (68.5%); активна ($10 \leq \text{потік} \leq 1000$): 171 година (28.5%); дуже активна (≥ 1000): 18 годин (3.0%).

```

1
2 bins = [-np.inf, 10, 1000, np.inf]
3 labels = ["тиха", "активна", "дуже активна"]
4
5 M["група"] = pd.cut(
6     M["P_gt_10_max"], bins=bins, labels=labels, right=False
7 ).astype(str)
8
9 group_counts = M["група"].value_counts()
10 print(group_counts)
✓ [17] 50ms

```

```


група
тиха          411
активна       171
дуже активна   18
Name: count, dtype: int64

```

Етап 5. П'ять графіків — п'ять питань

• Графік 1. Розподіл значень потоку електронів $E > 2.0$ (середнє за годину)

Побудова: Гістограми в лінійному та десятково-логарифмічному ($\log_{10}$) масштабах.




Висновок: Розподіл потоку електронів має виражену правосторонню асиметрію з поодинокими екстремальними викидами до $2.5 \cdot 10^5$ Electrons / (cm² · s · sr)

sr), через що середнє арифметичне значення (81\,842.5) суттєво перевершує медіану (69\,712.5).

- **Графік 2. Діаграма розмаху швидкості сонячного вітру за групами активності**


Побудова: Діаграма типу boxplot для груп «тиха», «активна» та «дуже активна».



Висновок: У період максимального радіаційного шторму (група «дуже активна») медіанна швидкість сонячного вітру зростає до 556.0 км/с (проти 524.0 км/с у тихий період), причому в активній фазі зафіксовано 12 екстремальних викидів швидкості у діапазоні 728-806 км/с.

- **Графік 3. Кореляційний зв'язок між радіопотоком F10.7 та швидкістю вітру**


Побудова: Діаграма розсіювання (scatter plot) у подвійному логарифмічному масштабі з розрахунком коефіцієнта кореляції Пірсона.



Висновок: Коефіцієнт лінійної кореляції між радіопотоком F10.7 та швидкістю вітру становить $r = 0.06$, що свідчить про практичну відсутність взаємного лінійного зв'язку між цими фракціями частинок у межах спостережуваного часового вікна.

- **Графік 4. Розподіл тривалості станів космічної погоди за групами**


Побудова: Стовпчикова діаграма кількості годин та відсоткової частки кожної категорії.



Висновок: Переважну більшість часу спостережень магнітосфера перебувала у спокійному стані (411 годин, або 68.5%), тоді як екстремально небезпечна фаза радіаційного шторму («дуже активна») тривала лише 18 годин (3.0% загального часу).

• Графік 5. Часова динаміка максимуму потоку $P>10$ за серпень–вересень 2017 року

Побудова: Лінійний часовий графік у напівлогарифмічному масштабі (`plt.yscale('log')`).




Висновок: Часовий ряд чітко відображає початок сонячного протонного шторму 4 вересня з виходом на абсолютний максимум 10–11 вересня, коли інтенсивність потоку високоенергетичних протонів зросла більш ніж на три


порядки відносно фону.

Етап 6. Два графіки одних і тих самих даних

□ **Висновок з Графіка 1 (лінійна шкала, 28.08 — 05.09):** Людина, що бачила лише перший графік, зробить висновок, що погода на початку вересня мала спокійний потік протонів, за виключанням маленького сплеску 5 вересня, проте не матиме ніякого уявлення про те яким великим був сплеск насправді, де він закінчився і як довго він тривав. Імовірно людина не вважатиме це значним сплеском взагалі. Так само людина не матиме жодного уявлення про погоду в решті місяця.



□ **Висновок з Графіка 2 (логарифмічна шкала, повний діапазон):** Дозволяє побачити реальну динаміку сонячної активності, зафіксувати сплеск надзвичайної потужності та оцінити тривалість післясвічення радіаційного шторму.




□ **Ключові технічні відмінності між графіками:**

- *Ширина часового інтервалу:* Графік 1 охоплює лише перший тиждень (до 5 вересня), тоді як Графік 2 охоплює весь місяць.
- *Масштаб осі ординат:* Графік 1 використовує лінійну вісь Y, яка приховує фонові варіації, а Графік 2 побудовано на логарифмічній шкалі, що стискає порядки та уможливорює порівняння малих і екстремальних величин.

□ **Обґрунтування власного графіка (Завдання 6.2):**

Для об'єктивного представлення побудовано графік на повну тривалість спостережень у логарифмічному масштабі з виділенням періоду сонячної бурі. Це забезпечило збереження деталей фонових коливань без втрати інформації про піки спалаху.



Етап 7. Три спостереження та ваше питання

Три аналітичні спостереження:

Спостереження 1:

Медіана краще відображує середній потік електронів, оскільки середнє значення потоку спотворюється малочисельними даними з великим значенням. Це видно на 1 графіку 5 етапу

Спостереження 2:

Середня швидкість сонячного вітру та показник сонячного радіовипромінювання F10.7 мають практично нульову лінійну кореляцію $r = 0.06$, що свідчить про те, що сплески сонячного випромінювання та швидкість потоку плазми біля Землі не пов'язані прямою синхронною залежністю, що видно на 3 графіку 5 етапу.

Спостереження 3:

Прилад SOHO CELIAS мав тривалий безперервний збій реєстрації сонячного вітру тривалістю рівно 8 годин підряд (з 07:00 до 14:00 4 вересня 2017 року), коли замість фізичних даних передавався технічний маркер -1 (видно в завданнях 3.2 та 4.3)

Відповідь на індивідуальне завдання (Варіант 15):

Питання: Порівняйте медіану вашого потоку за перший і за другий тиждень спостережень. У скільки разів вони відрізняються?

Медіана потоку електронів за 1 тиждень складає $452 \text{ Elctrons}/(\text{cm}^2 * \text{s} * \text{sr})$. За другий - $6790 \text{ Elctrons}/(\text{cm}^2 * \text{s} * \text{sr})$. Медіана за другий тиждень зросла у 15.02 разів, що безпосередньо спричинено початком потужного циклу сонячних спалахів і геомагнітної бурі з 5 вересня.

ВИСНОВКИ

Проведено повний цикл первинного розбору неструктурованого набору даних спостережень космічної погоди: виділено три автономні таблиці різної дискретності, очищено артефакти сенсорного збою (значення -1.0) та нормалізовано часові ряди до єдиної погодинної шкали в датафреймі M обсягом 600 рядків.

Експортовано результуючий файл master_hourly.csv, валідований автоматичними перевірками блоку на виконання без помилок на чистому ядрі.

Досліджено сонячний шторм вересня 2017 року, підтверджено наявність екстремальних протонних стрибків і з'ясовано, що лінійний масштаб у поєднанні з обмеженим часовим вікном здатен повністю викривити інтерпретацію фізичних процесів.